

学校代码：10246
学号：12345678901

復旦大學

博士學位論文

(學術學位)

基于深度学习的自然语言处理关键技术研究

Research on Key Technologies of Natural Language
Processing Based on Deep Learning

院 系：计算机科学技术学院

专 业：计算机科学与技术

姓 名：张三

指导教师：李四 教授

完成日期：2026年6月

复旦大学
学位论文独创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。论文中除特别标注的内容外，不包含任何其他个人或机构已经发表或撰写过的研究成果。对本研究做出重要贡献的个人和集体，均已在论文中作了明确的声明并表示了谢意。本声明的法律结果由本人承担。

作者签名: _____ 日期: _____ 年 _____ 月 _____ 日

复旦大学
学位论文使用授权声明

本人完全了解复旦大学有关收藏和利用博士、硕士学位论文的规定，即：学校有权收藏、使用并向国家有关部门或机构送交论文的印刷本和电子版本；允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其它复制手段保存论文。涉密学位论文在解密后遵守此规定。

作者签名: _____ 导师签名: _____ 日期: _____ 年 _____ 月 _____ 日

指导小组成员名单

李四	教授	复旦大学计算机科学技术学院
王五	教授	复旦大学计算机科学技术学院
赵六	副教授	复旦大学计算机科学技术学院

nil

摘要	v
Abstract	vii
绪论	3
研究背景与意义	3
国内外研究现状	3
预训练语言模型	3
文本生成技术	3
知识图谱技术	4
研究内容与贡献	4
论文组织结构	4
相关工作	5
深度学习基础	5
神经网络基础	5
循环神经网络	5
注意力机制与Transformer	5
预训练语言模型	5
词向量表示	5
上下文化词表示	6
文本生成方法	6
序列到序列模型	6
解码策略	6
知识图谱相关技术	6
本章小结	6

方法	7
多粒度语义增强的预训练策略	7
方法概述	7
模型架构	7
预训练任务设计	7
融合知识的文本生成框架	7
框架设计	7
知识检索模块	7
知识融合机制	8
基于对比学习的关系抽取方法	8
问题形式化	8
对比学习框架	8
数据增强策略	8
本章小结	8
实验与分析	9
实验设置	9
数据集	9
基线方法	9
实现细节	9
预训练语言模型实验结果	9
文本生成实验结果	10
关系抽取实验结果	10
消融实验	10
本章小结	10
总结与展望	11
工作总结	11

未来展望	11
参考文献	13
致谢	15

摘 要

随着人工智能技术的快速发展，深度学习在自然语言处理领域取得了显著的突破。本文系统地研究了基于深度学习的自然语言处理关键技术，主要包括预训练语言模型、文本生成与知识图谱构建三个方面。

在预训练语言模型方面，本文提出了一种新的预训练策略，通过引入多粒度的语义信息，有效提升了模型对中文文本的理解能力。实验结果表明，该方法在多个中文自然语言理解基准数据集上取得了优于基线模型的性能。

在文本生成方面，本文设计了一种融合知识的文本生成框架。该框架通过在解码阶段动态引入外部知识，解决了传统生成模型中知识不足导致的事实性错误问题。在多个文本生成任务上的实验验证了该框架的有效性。

在知识图谱构建方面，本文提出了一种基于对比学习的实体关系抽取方法。该方法通过构造正负样本对进行对比训练，显著提升了低资源场景下的关系抽取性能。

本文的研究成果对推动深度学习在自然语言处理中的应用具有重要的理论意义和实用价值。

关键词：深度学习，自然语言处理，预训练模型，文本生成，知识图谱

中图分类号：TP391

Abstract

With the rapid development of artificial intelligence, deep learning has achieved significant breakthroughs in the field of natural language processing (NLP). This dissertation systematically investigates key technologies of NLP based on deep learning, focusing on three main aspects: pre-trained language models, text generation, and knowledge graph construction.

Regarding pre-trained language models, this dissertation proposes a novel pre-training strategy that incorporates multi-granularity semantic information, effectively enhancing the model's ability to understand Chinese text. Experimental results demonstrate that the proposed method achieves superior performance compared to baseline models on multiple Chinese natural language understanding benchmarks.

In the area of text generation, this dissertation designs a knowledge-enhanced text generation framework. By dynamically incorporating external knowledge during the decoding phase, this framework addresses the factual error issues caused by insufficient knowledge in traditional generation models. Experiments on multiple text generation tasks validate the effectiveness of the proposed framework.

For knowledge graph construction, this dissertation proposes a contrastive learning-based entity relation extraction method. By constructing positive and negative sample pairs for contrastive training, this method significantly improves relation extraction performance in low-resource scenarios.

The research contributions of this dissertation hold both theoretical significance and practical value for advancing the application of deep learning in natural language processing.

Keywords: Deep Learning, Natural Language Processing, Pre-trained Models, Text Generation, Knowledge Graph

第一章

绪论

1.1 研究背景与意义

自然语言处理（Natural Language Processing, NLP）是人工智能领域的重要分支，旨在让计算机能够理解、生成和处理人类语言。近年来，深度学习技术的快速发展为自然语言处理带来了革命性的变化，使得机器在文本理解、生成和推理等任务上的能力得到了显著提升。

随着互联网和移动设备的普及，文本数据呈爆炸式增长。如何有效地从海量文本数据中提取有价值的信息，成为了学术界和工业界共同关注的重要课题。传统的自然语言处理方法主要依赖于手工设计的特征和规则，这些方法不仅耗时费力，而且在处理复杂语言现象时往往力不从心。

深度学习方法通过端到端的学习方式，能够自动地从数据中学习有效的特征表示，避免了繁琐的特征工程过程。特别是近年来预训练语言模型的出现，如BERT、GPT系列等，极大地推动了自然语言处理技术的发展。

1.2 国内外研究现状

1.2.1 预训练语言模型

预训练语言模型是当前自然语言处理领域最为活跃的研究方向之一。自2018年BERT模型提出以来，预训练语言模型经历了快速的发展。研究者们从模型架构、预训练任务、训练策略等多个角度对预训练语言模型进行了改进和优化。

在模型架构方面，Transformer架构已经成为主流选择。基于Transformer的模型包括编码器模型（如BERT）、解码器模型（如GPT）和编码器-解码器模型（如T5）等。

1.2.2 文本生成技术

文本生成是自然语言处理中的一项基础任务，旨在让机器能够产生流畅、连贯且有意义的文本。传统的文本生成方法主要基于模板和规则，生成的文本往往比较生硬和机械。

近年来，基于深度学习的文本生成方法取得了显著进展。序列到序列模型、变分自编码器、生成对抗网络等模型被广泛应用于文本生成任务中。

1.2.3 知识图谱技术

知识图谱是一种用图结构来表示实体及其之间关系的知识表示方法。知识图谱的构建涉及实体识别、关系抽取、知识融合等多个关键技术。

1.3 研究内容与贡献

本文的主要研究内容和贡献包括以下几个方面：

（1）提出了一种新的预训练语言模型训练策略，通过引入多粒度语义信息提升模型的中文文本理解能力。

（2）设计了融合知识的文本生成框架，有效解决了生成文本的事实性问题。

（3）提出了基于对比学习的实体关系抽取方法，提升了低资源场景下的抽取性能。

1.4 论文组织结构

本文共分为五章，各章内容安排如下：

第一章为绪论，介绍了研究背景、国内外研究现状、研究内容与贡献以及论文的组织结构。

第二章为相关工作，详细介绍了本文涉及的基础理论和相关技术。

第三章为方法，详细阐述了本文提出的各项方法和技术方案。

第四章为实验与分析，介绍了实验设置、结果和分析。

第五章为总结与展望，总结了全文工作并指出了未来的研究方向。

第二章 相关工作

2.1 深度学习基础

2.1.1 神经网络基础

深度学习的基础是人工神经网络。人工神经网络由大量的神经元节点组成，通过连接权重来传递信息。典型的前馈神经网络包括输入层、隐藏层和输出层。通过反向传播算法，网络可以根据损失函数的梯度来更新连接权重，从而学习数据中的模式。

2.1.2 循环神经网络

循环神经网络（Recurrent Neural Network, RNN）是一种专门用于处理序列数据的神经网络架构。与前馈神经网络不同，RNN具有循环连接，能够将前一时刻的隐藏状态传递到当前时刻，从而捕获序列中的时序依赖关系。

长短期记忆网络（Long Short-Term Memory, LSTM）和门控循环单元（Gated Recurrent Unit, GRU）是两种常用的改进型RNN架构，它们通过引入门控机制有效地缓解了标准RNN中的梯度消失问题。

2.1.3 注意力机制与Transformer

注意力机制允许模型在处理序列时动态地关注不同位置的信息。自注意力（Self-Attention）机制让序列中的每个位置都能直接关注其他所有位置，从而有效地捕获长距离依赖关系。

Transformer架构完全基于自注意力机制构建，摒弃了循环和卷积结构。它由编码器和解码器两部分组成，每一部分都包含多层自注意力层和前馈神经网络层。Transformer的并行计算能力使其在训练效率上远超RNN。

2.2 预训练语言模型

2.2.1 词向量表示

词向量表示是自然语言处理的基础技术之一。传统的独热编码方法将词语表示为高维稀疏向量，无法捕获词语之间的语义关系。分布式词向量表示（如Word2Vec、GloVe）通过将词语映射到低维密集向量空间，有效地编码了词语的语义信息。

2.2.2 上下文化词表示

与静态词向量不同，上下文化词表示能够根据词语所在的上下文动态地生成词向量。ELMo通过双向LSTM来获取上下文化的词表示，而BERT则通过双向Transformer编码器来实现这一目标。

2.3 文本生成方法

2.3.1 序列到序列模型

序列到序列（Sequence-to-Sequence, Seq2Seq）模型是文本生成任务中最基本的架构之一。该模型由编码器和解码器组成，编码器将输入序列编码为固定长度的向量表示，解码器则基于该向量逐步生成输出序列。

2.3.2 解码策略

文本生成中常用的解码策略包括贪心搜索、束搜索（Beam Search）、采样方法（如Top-k采样、核采样）等。不同的解码策略会显著影响生成文本的质量和多样性。

2.4 知识图谱相关技术

知识图谱的构建是一个系统性工程，涉及知识抽取、知识表示学习、知识融合等多个环节。在知识抽取方面，实体关系抽取是核心任务之一，旨在从非结构化文本中识别实体并抽取实体之间的语义关系。

2.5 本章小结

本章对与本文研究相关的基础理论和技术进行了全面的介绍，包括深度学习基础、预训练语言模型、文本生成方法和知识图谱技术。这些内容为后续章节中提出的方法提供了理论基础。

第三章 方法

3.1 多粒度语义增强的预训练策略

3.1.1 方法概述

本节提出一种多粒度语义增强的预训练策略，旨在提升预训练语言模型对中文文本的理解能力。该方法的核心思想是在预训练阶段同时建模字级、词级和短语级的语义信息，使模型能够从不同粒度理解文本的含义。

3.1.2 模型架构

本方法基于Transformer编码器架构，在标准的自注意力机制基础上引入了多粒度注意力模块。该模块通过不同尺度的卷积核捕获不同粒度的局部语义特征，然后与全局自注意力特征进行融合。

3.1.3 预训练任务设计

本方法设计了三个互补的预训练任务：

（1）掩码语言模型任务：与BERT类似，随机掩码输入文本中的部分标记并预测被掩码的标记。

（2）词级语义预测任务：通过中文分词工具获取词级别的标注，在预训练过程中预测被掩码区域的词级语义标签。

（3）短语级对比学习任务：通过构造正负样本对进行对比学习，使模型能够区分语义相近和语义不相关的短语。

3.2 融合知识的文本生成框架

3.2.1 框架设计

本节提出一种融合知识的文本生成框架。该框架的核心思想是在文本生成的解码阶段动态引入外部知识，以提高生成文本的事实准确性和信息丰富度。

3.2.2 知识检索模块

知识检索模块负责根据当前的生成上下文从外部知识库中检索相关的知识条目。该模块采用双塔架构，分别对生成上下文和知识条目进行编码，然后通过向量相似度计算来检索最相关的知识。

3.2.3 知识融合机制

知识融合机制将检索到的知识信息注入到生成过程中。本文设计了一种门控注意力融合机制，通过可学习的门控参数动态地控制知识信息对生成过程的影响程度。

3.3 基于对比学习的关系抽取方法

3.3.1 问题形式化

给定一个句子和其中标注的两个实体，关系抽取的目标是预测这两个实体之间的语义关系类型。形式化地，给定输入句子及实体对，模型需要从预定义的关系类型集合中选择正确的关系类型。

3.3.2 对比学习框架

本方法的核心是利用对比学习来增强关系表示的区分能力。通过构造正负样本对，使得具有相同关系类型的实体对在特征空间中靠近，不同关系类型的实体对则远离。

3.3.3 数据增强策略

为了应对低资源场景下训练数据不足的问题，本文设计了一种面向关系抽取的数据增强策略。该策略通过实体替换、上下文改写等操作生成新的训练样本，在保持关系语义不变的前提下增加训练数据的多样性。

3.4 本章小结

本章详细介绍了本文提出的三个核心方法：多粒度语义增强的预训练策略、融合知识的文本生成框架以及基于对比学习的关系抽取方法。每个方法都针对特定问题进行了创新性的设计。

第四章 实验与分析

4.1 实验设置

4.1.1 数据集

本文在多个公开的中英文自然语言处理基准数据集上进行了实验验证。对于预训练语言模型实验，使用了CLUE基准数据集中的多个任务，包括文本分类、自然语言推理、语义相似度计算等。

对于文本生成实验，使用了中文摘要生成数据集LCSTS和对话生成数据集KdConv。对于关系抽取实验，使用了中文关系抽取数据集DuIE和英文数据集TACRED。

4.1.2 基线方法

为了验证本文所提方法的有效性，选择了以下基线方法进行比较：

- (1) BERT-base：标准的BERT基础模型。
- (2) RoBERTa-wwm：全词掩码的中文RoBERTa模型。
- (3) ERNIE：百度提出的知识增强型预训练模型。
- (4) MacBERT：采用MLM as correction策略的预训练模型。

4.1.3 实现细节

所有模型均基于PyTorch框架实现。预训练模型使用了12层Transformer编码器，隐藏层维度为768，注意力头数为12。预训练使用了8块NVIDIA A100 GPU，批次大小为256，学习率为 $1e-4$ ，训练了100万步。

微调阶段使用了单块GPU，批次大小为32，学习率为 $2e-5$ ，训练5到10个epoch。所有实验结果均为5次不同随机种子运行的平均值。

4.2 预训练语言模型实验结果

本节展示了多粒度语义增强的预训练策略在中文自然语言理解任务上的实验结果。

实验结果表明，本文提出的多粒度语义增强策略在CLUE基准数据集的多个任务上均取得了优于基线模型的性能。在文本分类任务（TNEWS）上，准确率提升了1.2个百分点；在自然语言推理任务（CMNLI）上，准确率提升了0.8个百分点；在语义相似度任务（AFQMC）上，准确率提升了1.5个百分点。

这些结果验证了多粒度语义信息对提升模型中文理解能力的有效性。特别是在需要细粒度语义理解的任务上，本文方法的优势更为明显。

4.3 文本生成实验结果

融合知识的文本生成框架在摘要生成和对话生成两个任务上进行了实验。

在摘要生成任务上，本文方法在ROUGE-1、ROUGE-2和ROUGE-L指标上分别取得了44.3、21.7和40.8的分数，均优于对比方法。在对话生成任务上，本文方法在BLEU-4指标上提升了2.1个点，在人工评估的事实准确性指标上提升了15个百分点。

4.4 关系抽取实验结果

基于对比学习的关系抽取方法在标准和低资源两种设置下进行了实验。

在标准设置下，本文方法在DuIE数据集上的F1值达到了72.5，比最佳基线方法提升了1.8个百分点。在低资源设置下（仅使用10%的训练数据），本文方法的F1值为63.2，比最佳基线方法提升了4.3个百分点，展示了对比学习在数据稀缺场景下的显著优势。

4.5 消融实验

为了验证各模块的贡献，本文设计了一系列消融实验。实验结果表明，每个模块都对最终性能有着正面的贡献，去除任何一个模块都会导致性能下降。

4.6 本章小结

本章通过大量实验验证了本文提出的三种方法的有效性。实验结果表明，本文方法在多个任务和数据集上均取得了优于现有方法的性能，证明了所提方法的通用性和有效性。

第五章 总结与展望

5.1 工作总结

本文围绕基于深度学习的自然语言处理关键技术展开研究，主要取得了以下成果：

（1）提出了多粒度语义增强的预训练策略。通过在预训练阶段同时建模字级、词级和短语级的语义信息，有效提升了预训练语言模型对中文文本的理解能力。在CLUE基准数据集上的实验表明，该策略在多个中文自然语言理解任务上均取得了显著的性能提升。

（2）设计了融合知识的文本生成框架。该框架通过知识检索和门控注意力融合机制，在生成过程中动态引入外部知识，有效解决了传统生成模型中的事实性错误问题。在摘要生成和对话生成任务上的实验验证了该框架的有效性。

（3）提出了基于对比学习的实体关系抽取方法。通过构造正负样本对进行对比训练，并结合面向关系抽取的数据增强策略，显著提升了低资源场景下的关系抽取性能。

5.2 未来展望

尽管本文取得了一些有意义的研究成果，但仍有许多值得深入探索的方向：

（1）多模态预训练模型：当前本文的方法主要面向纯文本数据，未来可以将多粒度语义增强策略扩展到多模态场景，融合图像、语音等多种模态的信息。

（2）更高效的知识融合方式：目前的知识融合机制虽然有效，但在推理效率方面仍有提升空间。探索更高效的知识融合方式是重要的研究方向。

（3）跨语言和跨领域泛化：增强模型在不同语言 and 不同领域之间的泛化能力，减少对特定领域标注数据的依赖。

（4）可解释性研究：提升深度学习模型在自然语言处理任务中的可解释性，使模型的决策过程更加透明和可信。

参考文献

- [1] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]. Proceedings of NAACL-HLT, 2019: 4171-4186.
- [2] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]. Advances in Neural Information Processing Systems, 2017: 5998-6008.
- [3] Radford A, Wu J, Child R, et al. Language Models are Unsupervised Multitask Learners[J]. OpenAI Blog, 2019, 1(8): 9.
- [4] Liu Y, Ott M, Goyal N, et al. RoBERTa: A Robustly Optimized BERT Pretraining Approach[J]. arXiv preprint arXiv:1907.11692, 2019.
- [5] Sun Y, Wang S, Li Y, et al. ERNIE: Enhanced Representation through Knowledge Integration[J]. arXiv preprint arXiv:1904.09223, 2019.
- [6] Cui Y, Che W, Liu T, et al. Pre-Training with Whole Word Masking for Chinese BERT[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29: 3504-3514.
- [7] Raffel C, Shazeer N, Roberts A, et al. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer[J]. Journal of Machine Learning Research, 2020, 21(1): 5485-5551.
- [8] Lewis M, Liu Y, Goyal N, et al. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension[C]. Proceedings of ACL, 2020: 7871-7880.
- [9] Brown T B, Mann B, Ryder N, et al. Language Models are Few-Shot Learners[C]. Advances in Neural Information Processing Systems, 2020, 33: 1877-1901.
- [10] Xu L, Hu H, Zhang X, et al. CLUE: A Chinese Language Understanding Evaluation Benchmark[C]. Proceedings of COLING, 2020: 4762-4772.
- [11] Bordes A, Usunier N, Garcia-Duran A, et al. Translating Embeddings for Modeling Multi-relational Data[C]. Advances in Neural Information Processing Systems, 2013: 2787-2795.
- [12] Ji S, Pan S, Cambria E, et al. A Survey on Knowledge Graphs: Representation, Acquisition, and Applications[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 33(2): 494-514.
- [13] Li Y, Li D, Yin Y, et al. DuIE: A Large-scale Chinese Knowledge Graph Relation Extraction Dataset[C]. Natural Language Processing and Chinese Computing, 2019: 811-819.

参考文献

- [14] Zhang Y, Zhong V, Chen D, et al. Position-aware Attention and Supervised Data Improve Slot Filling[C]. Proceedings of EMNLP, 2017: 35-45.
- [15] Chen T, Kornblith S, Norouzi M, et al. A Simple Framework for Contrastive Learning of Visual Representations[C]. International Conference on Machine Learning, 2020: 1597-1607.

致 谢

时光荏苒，转眼间博士生涯即将结束。回顾这几年的学习和研究历程，我心中充满了感激之情。在此，我要向所有给予我帮助和支持的人表示衷心的感谢。

首先，我要感谢我的导师李四教授。李老师严谨的治学态度、渊博的学术知识和宽厚的为人处世之道，深深地影响了我。在论文选题、研究方法、论文撰写等各个环节，李老师都给予了我悉心的指导和耐心的帮助。李老师对科研的热情和执着，是我永远学习的榜样。

感谢王五教授和赵六副教授在我的研究过程中提出的宝贵建议和意见。他们在学术讨论中的独到见解，帮助我拓宽了研究视野，解决了许多难题。

感谢实验室的同门们，我们一起讨论学术问题，分享研究心得，共同度过了许多难忘的时光。特别感谢张七、李八和王九同学在实验和论文方面给予的帮助。

感谢复旦大学计算机科学技术学院提供的良好科研环境和学术氛围，感谢学院的各位老师和行政人员在学习和生活方面给予的关怀和帮助。

最后，我要特别感谢我的家人。感谢父母多年来的养育之恩和无条件的支持与理解，是你们的爱和鼓励，支撑着我走过了求学路上的每一个困难时刻。感谢爱人的陪伴和包容，你的理解和支持是我最大的动力。

谨以此文献给所有关心和帮助过我的人。